

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



Xử lý ngôn ngữ tự nhiên
Học kỳ 2 2025 - 2026

BÀI TẬP LỚN

TRÍCH XUẤT THÔNG TIN
VÀ PHÂN TÍCH NGỮ
NGHĨA HỢP ĐỒNG PHÁP
LÝ

GVHD: BÙI VĂN QUỐC BẢO

Sinh viên thực hiện: Nguyễn Võ Thiên Bảo – 2310250
Giang Phi Vân – 2313867
Nguyễn Huy Lượng – 2311997

Thành phố Hồ Chí Minh, Tháng 4/2026



Mục lục

1	Tiền xử lý và Phân tích cú pháp	3
1.1	Tách mệnh đề (Clause Splitting)	3
1.1.1	Mục tiêu bài toán	3
1.1.2	Phương pháp tiếp cận và Triển khai	3
1.1.3	Kết quả đầu ra	4
1.2	Phân cụm danh từ (Noun Phrase Chunking)	5
1.2.1	Mục tiêu bài toán	5
1.2.2	Phương pháp tiếp cận và Triển khai	5
1.2.3	Kết quả đầu ra	6
1.3	Trích xuất quan hệ phụ thuộc (Dependency Relation Extraction)	7
1.3.1	Mục tiêu bài toán	7
1.3.2	Phương pháp tiếp cận và Triển khai	7
1.3.3	Kết quả đầu ra	7
2	Trích xuất thông tin và Phân tích ngữ nghĩa	9
2.1	Nhận dạng thực thể tên riêng (Named Entity Recognition - NER)	9
2.1.1	Mục tiêu bài toán	9
2.1.2	Phương pháp tiếp cận: Mô hình PhoBERT	9
2.1.3	Quy trình triển khai	9
2.1.4	Kết quả đạt được	10
2.2	Gắn nhãn vai trò ngữ nghĩa (SRL)	11
2.2.1	Mục tiêu bài toán	11
2.2.2	Phương pháp tiếp cận: Mô hình PhoBERT	11
2.2.3	Quy trình triển khai	11
2.2.4	Kết quả đạt được	11
2.3	Phân loại ý định	12
2.3.1	Mục tiêu bài toán	12
2.3.2	Phương pháp tiếp cận và Triển khai	12
2.3.3	Đánh giá và Đối chiếu mô hình	13
2.3.4	Kết quả đầu ra	13



1 Tiền xử lý và Phân tích cú pháp

1.1 Tách mệnh đề (Clause Splitting)

1.1.1 Mục tiêu bài toán

Các hợp đồng pháp lý trong thực tế thường chứa những câu rất dài và phức tạp, đi kèm với nhiều mệnh đề phụ, điều kiện và các phép liệt kê. Việc xử lý trực tiếp những câu phức này gây khó khăn cho các tác vụ trích xuất thông tin phía sau. Do đó, mục tiêu của tác vụ này là phát triển một thuật toán có khả năng phân tách một câu phức thành các mệnh đề độc lập về mặt ngữ nghĩa, đảm bảo mỗi mệnh đề kết quả là một đơn vị có ý nghĩa hoàn chỉnh để phân tích riêng biệt.

1.1.2 Phương pháp tiếp cận và Triển khai

Để giải quyết bài toán, nhóm đã xây dựng một Pipeline xử lý kết hợp giữa luật (Rule-based) và phân tích cú pháp phụ thuộc (Dependency Parsing) thông qua thư viện `py_vncorenlp` và `nltk`. Quá trình triển khai được chia thành 3 bước cốt lõi:

1. Tiền xử lý, lọc và làm sạch văn bản:

- **Lọc mệnh đề hữu ích (`is_useful`):** Loại bỏ các dòng quá ngắn, cấu trúc đánh dấu điều khoản (ví dụ: "Điều 1.") và các cụm từ lặp khuôn thủ tục pháp lý. Sử dụng POS Tagging để đảm bảo câu giữ lại có ít nhất một Động từ (V) đóng vai trò *root*.
- **Làm sạch tiền tố (`clean_prefix`):** Sử dụng Regex để xóa bỏ các ký tự đánh dấu danh sách (như "a)", ", ", "1.1. ").
- **Phân từ (Word Segmentation):** Sử dụng bộ `wseg` của VnCoreNLP để chuẩn hóa từ ghép tiếng Việt.

2. Phân tích cấu trúc Chủ - Vị (`has_SV_structure`):

Sử dụng bộ phân tích cú pháp `parse` của VnCoreNLP. Một chuỗi được xác nhận là mệnh đề độc lập nếu cây cú pháp chứa nhãn phụ thuộc `sub` (Chủ ngữ) và nhãn `root` là Động từ (V). Thuật toán cũng bỏ qua các vế bắt đầu bằng từ điều kiện "nếu" để tránh phá vỡ cấu trúc logic.

3. Thuật toán tách mệnh đề đệ quy (`split_clause`):

Sử dụng `nltk.word_tokenize` để duyệt qua các từ nối phổ biến như "và", dấu phẩy ",",. Nếu việc chia cắt tại từ



nối tạo ra hai vế đều thỏa mãn cấu trúc Chủ - Vị, thuật toán sẽ thực hiện cắt và gọi đệ quy cho phần còn lại.

1.1.3 Kết quả đầu ra

Hệ thống xử lý thành công dữ liệu từ `raw_contracts.txt` và xuất kết quả ra `clauses.txt`. Mỗi dòng trong file kết quả tương ứng với một mệnh đề độc lập, đảm bảo tính mạch lạc về ngữ nghĩa và phục vụ tốt cho các bước xử lý NLP tiếp theo.



1.2 Phân cụm danh từ (Noun Phrase Chunking)

1.2.1 Mục tiêu bài toán

Sau khi các mệnh đề đã được tách rời ở Tác vụ 1.1, bước tiếp theo là xác định các thực thể hoặc khái niệm quan trọng thông qua việc phân cụm danh từ. Mục tiêu là nhóm các từ đơn lẻ có liên quan chặt chẽ về mặt ngữ pháp để tạo thành các cụm danh từ (Noun Phrases) hoàn chỉnh, giúp máy tính hiểu được các đối tượng cụ thể (ví dụ: "Hệ thống Quản lý Bệnh viện", "Bộ Y tế") thay vì các từ rời rạc.

1.2.2 Phương pháp tiếp cận và Triển khai

Nhóm tiếp tục sử dụng thư viện `py_vncorenlp` để thực hiện gán nhãn từ loại (POS Tagging) và xây dựng thuật toán trích xuất dựa trên tập luật về từ loại. Quy trình gồm các bước sau:

- Xác định tập từ loại mục tiêu (`is_compound_noun_part`):** Dựa trên đặc điểm ngôn ngữ học tiếng Việt, một cụm danh từ thường được cấu thành từ các từ loại sau:
 - N: Danh từ chung.
 - Np: Danh từ riêng.
 - Nc: Danh từ chỉ loại.
 - Nu: Danh từ đơn vị.
 - M: Số từ (thường đi kèm danh từ để chỉ số lượng).
- Thuật toán trích xuất (`extract_noun_phrases`):** Nhóm triển khai thuật toán duyệt tuyến tính qua danh sách các token đã được gán nhãn:
 - Hệ thống sẽ gom nhóm các token liên tiếp nhau nếu chúng đều thuộc tập từ loại mục tiêu đã xác định ở trên.
Ví dụ: "Hệ/N thống/N Quản/V lý/N" → "Hệ_thống"(Do "Quản" là động từ nên sẽ ngắt cụm tại đó).
 - Các từ trong cùng một cụm được kết nối với nhau bằng dấu gạch dưới (`_`) để tạo thành một đơn vị ngữ nghĩa duy nhất.
 - Chỉ các cụm có độ dài từ 2 token trở lên mới được coi là cụm danh từ phức hợp để trích xuất.



3. **Xử lý dữ liệu:** Dữ liệu đầu vào là file `clauses.txt` (kết quả từ Tác vụ 1.1). Thuật toán sẽ xử lý từng mệnh đề, trích xuất tất cả các cụm danh từ xuất hiện và lưu trữ chúng.

1.2.3 Kết quả đầu ra

Kết quả cuối cùng được lưu tại file `noun_phrases.txt`. Mỗi dòng trong file tương ứng với các cụm danh từ tìm thấy trong một mệnh đề, được phân cách rõ ràng. Việc phân cụm này tạo tiền đề quan trọng cho tác vụ trích xuất thực thể (NER) và phân tích quan hệ ở các giai đoạn sau của dự án.

1.3 Trích xuất quan hệ phụ thuộc (Dependency Relation Extraction)

1.3.1 Mục tiêu bài toán

Mục tiêu của tác vụ này là xác định các thành phần ngữ pháp cốt lõi trong một mệnh đề để hiểu được cấu trúc "Ai làm gì" hoặc "Cái gì như thế nào". Thay vì chỉ dừng lại ở việc liệt kê từ loại, hệ thống cần trích xuất được mối quan hệ giữa Động từ chính (Root/Verb) và các thành phần phụ thuộc trực tiếp như Chủ ngữ (Subject), Tân ngữ (Object) và Bổ ngữ (Modifier). Điều này giúp chuẩn hóa dữ liệu cho các tác vụ phân tích ý nghĩa sâu hơn.

1.3.2 Phương pháp tiếp cận và Triển khai

Nhóm sử dụng bộ công cụ `py_vncorenlp` với tính năng `parse` (Dependency Parsing) để xây dựng cây cú pháp cho từng mệnh đề. Quy trình triển khai cụ thể như sau:

- Xác định Động từ chính (Root Verb):** Hệ thống duyệt qua các từ trong mệnh đề để tìm token có nhãn phụ thuộc là `root` và từ loại là Động từ (V). Đây được coi là "trung tâm" của quan hệ phụ thuộc.
- Trích xuất các thành phần phụ thuộc (`extract_dependency_relations`):** Dựa trên chỉ số (`index`) của Động từ chính, thuật toán tìm kiếm tất cả các từ có quan hệ trực tiếp (nhãn `head` trùng với `index` của `root`). Các nhãn phụ thuộc được ánh xạ sang vai trò ngữ nghĩa tiếng Việt như sau:
 - `sub` → **Chủ ngữ**: Thực thể thực hiện hành động.
 - `dob` → **Tân ngữ**: Thực thể chịu tác động của hành động.
 - `vmod` → **Bổ ngữ**: Các thông tin bổ sung về thời gian, địa điểm hoặc cách thức.
- Cấu trúc hóa dữ liệu:** Kết quả được tổ chức dưới dạng một từ điển (dictionary) chứa các thành phần: *Chủ ngữ*, *Động từ chính*, *Tân ngữ*, *Bổ ngữ*. Nếu một thành phần không xuất hiện trong câu, giá trị tương ứng sẽ được để trống.

1.3.3 Kết quả đầu ra

Hệ thống xử lý tệp `clauses.txt` và lưu kết quả vào tệp `dependency_relations.txt`. Mỗi dòng kết quả thể hiện cấu trúc ngữ pháp tường minh của một mệnh đề pháp lý. Việc trích xuất thành công các bộ (Subject-Verb-Object) là bước đệm quan trọng để chuyển



đổi các điều khoản hợp đồng từ ngôn ngữ tự nhiên sang dạng cấu trúc dữ liệu máy tính có thể hiểu và kiểm tra logic.

2 Trích xuất thông tin và Phân tích ngữ nghĩa

2.1 Nhận dạng thực thể tên riêng (Named Entity Recognition - NER)

2.1.1 Mục tiêu bài toán

Tác vụ này hướng tới việc tự động nhận diện và phân loại các thực thể quan trọng trong văn bản hợp đồng vào các nhóm định trước như: Tên tổ chức/cá nhân (Bên A, Bên B), Ngày tháng, Địa điểm, Giá trị hợp đồng, v.v. Đây là bước then chốt để chuyển đổi văn bản phi cấu trúc thành thông tin có cấu trúc, phục vụ cho việc quản lý và tra cứu hợp đồng tự động.

2.1.2 Phương pháp tiếp cận: Mô hình PhoBERT

Nhóm lựa chọn sử dụng **PhoBERT** (`vinai/phobert-base`), một mô hình Transformer được huấn luyện trước (pre-trained) dành riêng cho tiếng Việt, dựa trên kiến trúc RoBERTa. PhoBERT cho thấy hiệu năng vượt trội trong các tác vụ NLP tiếng Việt nhờ khả năng hiểu ngữ cảnh và đặc thù từ ghép.

2.1.3 Quy trình triển khai

Quá trình xây dựng mô hình được thực hiện qua các giai đoạn sau:

1. **Chuẩn bị dữ liệu và Gán nhãn (BIO Tagging):** Dữ liệu được chuẩn hóa về định dạng BIO (Begin, Inside, Outside). Mỗi token trong câu được gán một nhãn tương ứng, ví dụ: **B-ORG** cho từ bắt đầu tên tổ chức, **I-ORG** cho các từ tiếp theo và **O** cho các từ không thuộc thực thể nào.
2. **Tiền xử lý (Preprocessing):**
 - **Phân từ:** Sử dụng `VnCoreNLP` để phân từ trước khi đưa vào mô hình để đảm bảo tính nhất quán với quá trình pre-train của PhoBERT.
 - **Tokenization:** Sử dụng `AutoTokenizer` của thư viện `transformers` để chuyển đổi các câu thành các ID vector, đồng thời xử lý vấn đề *subword* bằng cách căn chỉnh nhãn (label alignment) cho các token bị chia nhỏ.
3. **Kiến trúc mô hình và Huấn luyện:**



- Nhóm sử dụng lớp `AutoModelForTokenClassification` để tích hợp một lớp tuyến tính (Linear layer) lên trên kiến trúc PhoBERT nhằm thực hiện phân loại thực thể cho từng token.
 - **Tham số huấn luyện:** Sử dụng bộ tối ưu hóa AdamW, tốc độ học (learning rate) thấp (ví dụ: 5×10^{-5}) và kỹ thuật *Early Stopping* để tránh hiện tượng quá khớp (overfitting).
4. **Đánh giá:** Mô hình được đánh giá dựa trên các chỉ số *Precision*, *Recall* và *F1-score* trên tập dữ liệu kiểm tra (test set).

2.1.4 Kết quả đạt được

Mô hình PhoBERT đạt được độ chính xác cao trong việc nhận diện các thực thể có cấu trúc ổn định như Ngày tháng và Giá trị tiền tệ. Đối với các thực thể phức tạp như Tên công ty hoặc Nội dung điều khoản, mô hình vẫn thể hiện khả năng trích xuất tốt nhờ vào việc hiểu ngữ cảnh xung quanh thực thể trong mệnh đề pháp lý.



2.2 Gắn nhãn vai trò ngữ nghĩa (SRL)

2.2.1 Mục tiêu bài toán

2.2.2 Phương pháp tiếp cận: Mô hình PhoBERT

2.2.3 Quy trình triển khai

2.2.4 Kết quả đạt được

2.3 Phân loại ý định

2.3.1 Mục tiêu bài toán

Tác vụ này nhằm mục đích tự động phân loại các mệnh đề hợp đồng (đã được bóc tách ở Tác vụ 1.1) vào các nhóm ý định cụ thể (Intent), ví dụ: Điều khoản thanh toán, Điều khoản bảo mật, Điều khoản phạt vi phạm, v.v. Việc phân loại chính xác giúp hệ thống nhanh chóng định vị và trích xuất các thông tin quan trọng mà không cần rà soát toàn bộ văn bản.

2.3.2 Phương pháp tiếp cận và Triển khai

Để đánh giá hiệu quả của các kỹ thuật Xử lý Ngôn ngữ Tự nhiên khác nhau, nhóm đã xây dựng và đối chiếu hai mô hình: một mô hình học máy truyền thống (Baseline) và một mô hình học sâu tiên tiến (PhoBERT).

Mô hình 1: Baseline (TF-IDF + Logistic Regression)

- **Trích xuất đặc trưng:** Nhóm sử dụng `TfidfVectorizer` để chuyển đổi văn bản thành vector. Cấu hình `ngram_range=(1, 2)` được áp dụng để giữ lại thông tin ngữ cảnh của các cụm từ (bigrams), kết hợp với `max_features=1000` để kiểm soát số lượng chiều dữ liệu, tránh hiện tượng thừa thớt (sparsity).
- **Thuật toán phân loại:** Mô hình `LogisticRegression` được lựa chọn làm baseline do tốc độ huấn luyện nhanh và khả năng diễn giải tốt đối với các đặc trưng TF-IDF.
- **Dự đoán:** Mô hình được huấn luyện trên tập `dataset-update.csv` và tiến hành dự đoán ý định cho các mệnh đề chưa biết trong tệp `output/clauses.txt`. Kết quả được lưu tại `intent_classification_baseline.txt`.

Mô hình 2: Nâng cao (PhoBERT)

- **Chuẩn bị dữ liệu:** Sử dụng `LabelEncoder` để chuyển đổi nhãn văn bản thành các ID dạng số. Lớp `ContractDataset` kế thừa từ `torch.utils.data.Dataset` được xây dựng để tương thích với quy trình huấn luyện của thư viện Transformers.
- **Kiến trúc mô hình:** Sử dụng mô hình `vinai/phobert-base-v2` kết hợp với `AutoModelForSequenceClassification`. PhoBERT được tinh chỉnh (fine-tune) trên tập dữ liệu hợp đồng để tận dụng khả năng biểu diễn ngữ nghĩa theo ngữ cảnh tiếng Việt.



- **Huấn luyện:** Mô hình được huấn luyện trong 8 epochs sử dụng **Trainer** API với cấu hình `warmup_steps=10` và `weight_decay=0.01` để tối ưu hóa quá trình hội tụ.
- **Dự đoán:** Tương tự mô hình baseline, PhoBERT đưa ra dự đoán cho các mệnh đề thô và lưu kết quả tại `phobert_intent_classification.txt`.

2.3.3 Đánh giá và Đối chiếu mô hình

Để có cái nhìn khách quan về hiệu năng, nhóm đã xây dựng một script đối chiếu độc lập (Compare models).

- Hệ thống đọc kết quả từ cả hai tệp dự đoán và tiến hành so sánh từng dòng.
- Tính toán **Tỷ lệ đồng thuận (Agreement Rate)** giữa hai mô hình trên tập dữ liệu chưa biết (Unseen data).
- Các trường hợp hai mô hình đưa ra kết quả phân loại khác nhau (Mâu thuẫn) được trích xuất riêng ra tệp `model_disagreements.csv`. Việc phân tích các nhầm lẫn này đóng vai trò quan trọng trong việc tinh chỉnh tập dữ liệu huấn luyện và cải thiện mô hình ở các vòng lặp tiếp theo.

2.3.4 Kết quả đầu ra

Hệ thống xuất ra hai tệp kết quả dự đoán riêng biệt cho từng mô hình và một báo cáo phân tích đối chiếu, cho thấy rõ sự chênh lệch trong khả năng hiểu ngữ nghĩa giữa phương pháp đếm từ (TF-IDF) và phương pháp ngữ cảnh (PhoBERT).